





Kiến Trúc Xử Lý Trong Deep Learning

Phân biệt CPU, GPU và TPU: Từ Đa Năng Đến Chuyên Biệt Hóa.

Linh Hoạt Tuyệt Đối



CPU
(Xử lý logic phức tạp
tổng quát)

Cân Bằng



GPU
(Song song hóa
diện rộng)

Chuyên Biệt Hóa Cao




TPU
(Chuyên dụng cho
Toán Tensor/ASIC)




Xử lý tuần tự

Ít lỗi tính toán nhưng
xung nhịp cực cao.



Xử lý song song

Hàng ngàn lõi nhỏ hoạt
động đồng thời (Element-
wise operations).



Khối tính toán ma trận

Thiết kế triệt tiêu điều
khiển thừa, tối ưu riêng
cho Đại số tuyến tính.

CPU: Central Processing Unit



Bản chất

"Bộ não" tổng quát. Thực thi tác vụ logic phức tạp & chuỗi lệnh tuần tự. Bắt buộc để chạy hệ điều hành.


Hiệu suất

$10^9 - 10^{10}$ phép toán / giây.

Phát triển

Intel, AMD, Apple.

Vai trò của CPU trong Deep Learning




Dữ liệu thô
(Raw text/images)

Tiền xử lý & Data Pipeline
Nén/tách dữ liệu, chuẩn bị
luồng điều khiển.

Tokenization văn bản
Dữ liệu sẵn sàng đẩy
vào bộ tăng tốc.

GPU: Graphics Processing Unit



Bản chất

Ban đầu xử lý đồ họa, nay là nền tảng tính toán song song diện rộng (thông qua NVIDIA CUDA).


Hiệu suất

$10^{14} - 10^{17}$ phép toán / giây (Gấp hàng chục lần CPU cho nhân ma trận).


Phát triển

NVIDIA, AMD, Apple.

Vai trò của GPU trong Deep Learning



TPU: Tensor Processing Unit (ASIC)



Bản chất

Vi mạch tích hợp chuyên dụng (ASIC) do Google thiết kế từ gốc. Bỏ qua khối điều khiển thừa, tập trung toàn lực vào Đại số tuyến tính.

Công nghệ lõi

Trình biên dịch XLA. Tối ưu riêng cho phép toán Tensor & thuật toán Học sâu.

Thế hệ

v2 / v3 / v5. Tiết kiệm chi phí ~3 lần so với GPU khi xử lý lô dữ liệu (batches) khổng lồ.

Vai trò của TPU trong Deep Learning

Huấn Luyện Quy Mô Khổng Lồ

Mô hình Nền tảng
(Foundation Models)


Large Language Models (LLMs)



Mạng Transformers
siêu lớn

Hoạt động tối ưu nhất trên
hệ sinh thái JAX và TensorFlow.

Mảnh ghép hoàn chỉnh: Luồng xử lý Học sâu




**Chuyên biệt hóa nhiệm vụ
để đạt hiệu suất tối đa.**

Tổng quan kiến trúc phần cứng AI

	 CPU	 GPU	 TPU
Bản chất	Đa năng	Song song diện rộng	ASIC chuyên dụng
Kiến trúc	Xử lý tuần tự	Hàng ngàn lõi nhỏ	Khối ma trận Tensor
Điểm mạnh	Logic, linh hoạt	Nhân ma trận, đa dụng	Hiệu năng cực lớn, tiết kiệm chi phí
Vai trò DL	Data Pipeline	Training / Inference	Foundation Models siêu lớn
Phát triển	Intel / AMD / Apple	NVIDIA / AMD / Apple	Google

Bước tiếp theo: Vượt qua giới hạn phần cứng đơn lẻ



Khi các mô hình vượt quá khả năng của một GPU/TPU duy nhất, chúng ta cần mở rộng quy mô.

Khám phá kiến trúc Huấn luyện phân tán (Distributed Training) trên cụm GPU/TPU sử dụng Keras 3 hoặc JAX trong bài giảng tiếp theo.