


XLA COMPILER

Trình Biên Dịch **Hiệu Năng Cao** Cho **Học Sâu** (Deep Learning)



X Accelerated

L Linear

A lgebra



Một trình biên dịch (compiler) chuyên dụng do Google phát triển, tối ưu hóa đặc biệt cho Học sâu (Deep Learning) và Machine Learning.

LỊCH SỬ



Phát triển cùng phần cứng **TPU** để vắt kiệt **sức mạnh tính toán chuyên dụng**.

VẤN ĐỀ



Eager Execution chạy từng phép toán rời rạc trên thời gian thực -> Gây **lãng phí thời gian** đọc/ghi bộ nhớ liên tục


GIẢI PHÁP




Biên dịch và **tối ưu hóa** toàn bộ **đồ thị tính toán** thành **mã máy siêu tốc** trước khi thực thi.

Bí mật tốc độ: Gộp phép toán (Operation Fusing)

Without XLA



With XLA



XLA 'nấu chảy' các phép toán nối tiếp thành một nhân tính toán duy nhất, loại bỏ hoàn toàn độ trễ đọc/ghi VRAM.



NVIDIA GPU

Tối ưu hóa kiến trúc
lỗi CUDA.




Google TPU

Tương thích hoàn hảo
từ cấp độ phần cứng.



CPU Đa nhân

Tận dụng tối đa luồng
song song.



Khả năng mở rộng: Tự động song song hóa, phân tán khối lượng
tính toán hiệu quả trên hàng ngàn lõi hoặc nhiều thiết bị cùng lúc.

Ma trận Hệ sinh thái (XLA trong Frameworks)



JAX

Mức độ tích hợp: Native
(Thiết kế xoay quanh XLA)

```
@jax.jit
```



TensorFlow

Mức độ tích hợp:
Tùy chọn (Built-in)

```
@tf.function(jit_compile=True)
```



PyTorch

Mức độ tích hợp:
External / Đặc thù

```
torch_xla
```



Theory → Practice

Trăm nghe không bằng một... Code!

“Bạn có muốn thử viết một hàm đơn giản bằng JAX/TensorFlow, sử dụng @jit và tự mình đo lường sự khác biệt về tốc độ không?”