



Chương 5: Nền tảng của Học máy (Fundamentals of ML)

Học Sâu (Deep Learning)

Nội dung chương

1. Tối ưu hóa
(Optimization)
và Khái quát hóa
(Generalization)

2. Tác động của Dữ liệu Nhiều
(Noisy Data)

3. Các phương pháp Đánh giá Mô hình

4. Dung lượng Mô hình
(Model Capacity)

5. Các Phương pháp
Regularization

6. Giả thuyết Đa tạp (The Manifold Hypothesis)

7. Tổng kết

Sự giằng co cốt lõi trong Học máy




Tối ưu hóa (Optimization): Quá trình điều chỉnh mô hình để đạt hiệu suất tốt nhất trên tập dữ liệu huấn luyện (Training data).



Khái quát hóa (Generalization): Khả năng mô hình dự đoán chính xác trên dữ liệu hoàn toàn mới chưa từng thấy (Test data).

Mâu thuẫn: Mục tiêu là đạt Generalization cao nhất. Tuy nhiên, Gradient Descent chỉ tác động trực tiếp vào Optimization. Sau một thời gian, Optimization càng tốt thì Generalization lại càng đi xuống.

Hiện tượng Underfitting và Overfitting



Underfitting



Robust Fit



Overfitting




Underfitting (Chưa khớp): Mô hình quá đơn giản, không học được quy luật trong dữ liệu. (Vd: Dùng đường thẳng tuyến tính khớp dữ liệu parabol).

Robust Fit (Khớp chuẩn): Mô hình học được xu hướng thực sự của dữ liệu.

Overfitting (Quá khớp): Mô hình quá phức tạp, học thuộc lòng cả "nhiều" (noise), làm đường biên quyết định cong queo, mất tính tổng quát.


Hình 5.1: Mô phỏng Underfitting, Robust Fit và Overfitting

Vòng đời điển hình của mô hình (Universal Overfitting)



Hình 5.2: Hành vi Overfitting kinh điển

Dữ liệu không hợp lệ (Invalid Inputs)



Trong thực tế, dữ liệu chứa nhiều tạp âm, nhòe nhòe inoẹt. Ví dụ: MNIST có ảnh lỗi, mờ đến mức mắt người cũng không nhận diện được.



Nếu mạng có đủ **dung lượng**, nó sẽ “**học vẹt**” những hình nhiễu này, lãng phí tài nguyên ghi nhớ chúng → Suy giảm tính khái quát.

Hình 5.3: Các ảnh bị nhiễu nặng trong tập MNIST

Dữ liệu bị gán nhãn sai (Mislabeled Data)




Do sai sót chủ quan của con người (Human Error)

Dữ liệu có thể bị gán nhãn sai hoàn toàn (Vd: số 4 bị gán nhãn là số 9).

Mô hình cố uốn cong ranh giới quyết định để "chữa" nhãn sai này → Dẫn đến nhận diện sai hàng loạt ảnh tương tự trong tương lai.

Sự phình to của Kênh Nhiễu (Noise Channels)



Hình 5.5: Tác động của kênh nhiễu đến Accuracy



Thí nghiệm: Thêm ma trận toàn nhiễu trắng (white noise) hoặc toàn số 0 vào dữ liệu MNIST.




Kết quả: Kể cả khi dữ liệu MNIST hợp lệ nguyên vẹn, mạng bị phân tâm. Validation Accuracy giảm rõ rệt.



Lý do: Mô hình vô tình tìm ra các mẫu (patterns) giả mạo trong tập nhiễu và sử dụng chúng để ra quyết định → Suy giảm Generalization.

Ngoại lai (Outliers) và Sự quá khớp



Điểm nhiễu thường là "**Ngoại lai**" (Outliers) - dữ liệu lạc lõng giữa quần thể lớp khác.




Gradient Descent nỗ lực cực độ để phân loại đúng 100% tập huấn luyện, ép ranh giới quyết định vươn xa ra ngoài bọc lấy outlier.



Hậu quả: Ranh giới quyết định trở nên **góc cạnh** thay vì là **đường cong mượt mà** bao quát.

Hình 5.6: Robust fit (trái) vs. Overfitting ngoại lai (phải)

Đặc trưng mơ hồ (Ambiguous features)



Vùng bất định (Uncertainty):
Vùng giao thoa nơi dữ liệu có
xác suất 50% lớp A và 50%
lớp B.

Vấn đề: Overfitting vạch
đường biên răng cưa uốn éo
để cố phân chia tách - thay vì
dùng đường thẳng thống kê.

Khắc phục: Phải cho phép
mô hình phạm lỗi trên tập
Train (Training Loss không
bao giờ bằng 0).

Hình 5.7: Overfitting trên vùng dữ liệu bất định

Tại sao phải chia 3 tập dữ liệu?




Huấn luyện không chỉ chỉnh "Tham số" (Weights/Biases) mà còn "Siêu tham số" (Hyperparameters - số lớp, learning rate) dựa trên điểm Validation.

Information Leak: Dùng Validation liên tục làm la bàn khiến mô hình gián tiếp "học lỏm" cấu trúc tập này → Overfit trên chính Validation.

Giải pháp: Bắt buộc cần tập thứ 3 (Tập Test) - Hoàn toàn mới, chỉ chạy đúng 1 lần trước khi ứng dụng thực tế.

Tách tập Validation đơn giản (Hold-out Validation)



Quy trình: Xáo trộn (Shuffle) và tách một phần cố định (vd: 20%) từ tập Training.



Ưu điểm:

Rất nhanh gọn, phù hợp khi khối lượng dữ liệu khổng lồ.



Nhược điểm:

Nếu dữ liệu ít, tập Validation không mang tính đại diện thống kê, sai số đánh giá lớn khi đổi seed.

Hình 5.8: Quy trình Hold-out Validation

Mã nguồn: Hold-out Validation


```
1 import numpy as np
2
3 num_val_samples = 10000
4 np.random.shuffle(data) # Xáo trộn ngẫu nhiên
5
6 # Tách 10k mẫu làm Validation
7 val_data = data[: num_val_samples]
8 train_data = data[num_val_samples :]
9
10 model = get_model ()
11 model.fit(train_data , epochs =20)
12 val_score = model.evaluate(val_data)
13
14
15 # Sau khi điều chỉnh hyperparameter thành công ,
16 # ta huấn luyện lại 1 mô hình tren toàn bộ Train + Validation
17 model = get_model ()
18 model.fit(np.concatenate ([train_data , val_data ]), epochs =20)
19 test_score = model.evaluate(test_data)
20
```

Xáo trộn ngẫu nhiên dữ liệu trước khi cắt.

Đánh giá bằng tập Validation riêng biệt.

Huấn luyện lại mô hình chốt trên toàn bộ Train + Validation.

Đánh giá chéo K-Lần (K-Fold Validation)



Quy trình: Giải quyết vấn đề dữ liệu thừa thớt bằng cách chia dữ liệu thành K phần.

Lặp K vòng: lấy 1 Fold làm Validation, K-1 Fold làm Training.

Điểm cuối là trung bình K điểm số.



Ưu điểm: Tận dụng tối đa dữ liệu, độ chính xác đánh giá cao.



Nhược điểm: Chi phí tài nguyên tính toán gấp K lần.

Hình 5.9: Quy trình K-Fold Validation (với K=3)

Mã nguồn: K-Fold Validation

```
1 k = 4
2 num_val_samples = len(data) // k
3 val_scores = []
4
5 for fold in range(k):
6     # Lay ra phan Validation rieng
7     val_data = data[num_val_samples * fold : num_val_samples * (fold + 1)]
8
9     # Gop phan dau va cuoi de tao thanh tap Train
10    train_data = np.concatenate(
11        [data[: num_val_samples * fold], data[num_val_samples * (fold + 1) :]], axis=0
12    )
13
14    model = get_model () # Khoi tao lai mo hinh moi hoàn toàn!
15    model.fit(train_data , epochs =100, batch_size =16)
16    score = model.evaluate(val_data)
17    val_scores.append(score)
18
19 average_val_score = np.mean(val_scores) # Lay trung bình
```

Vòng lặp K lần huấn luyện hoàn toàn độc lập.

Ghép nối các đoạn dữ liệu đầu/cuối để tạo tập Train.

Điểm đánh giá cuối cùng là trung bình (mean) của toàn bộ K vòng.