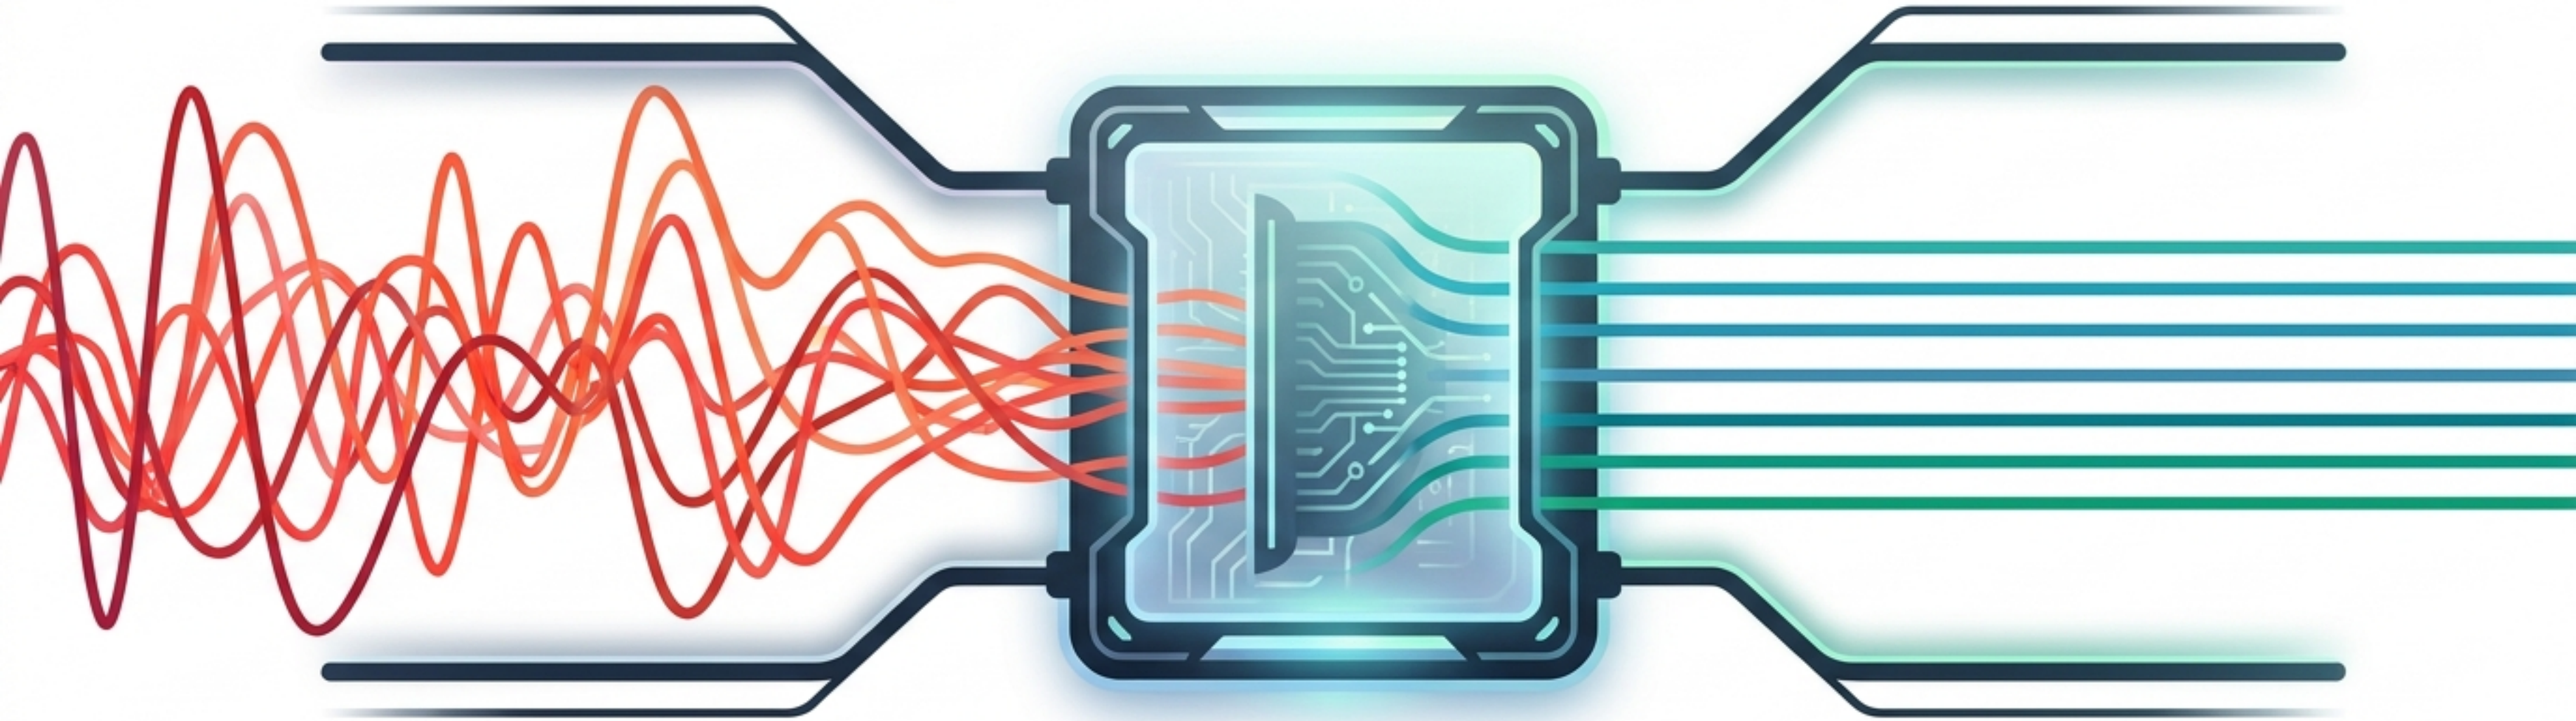


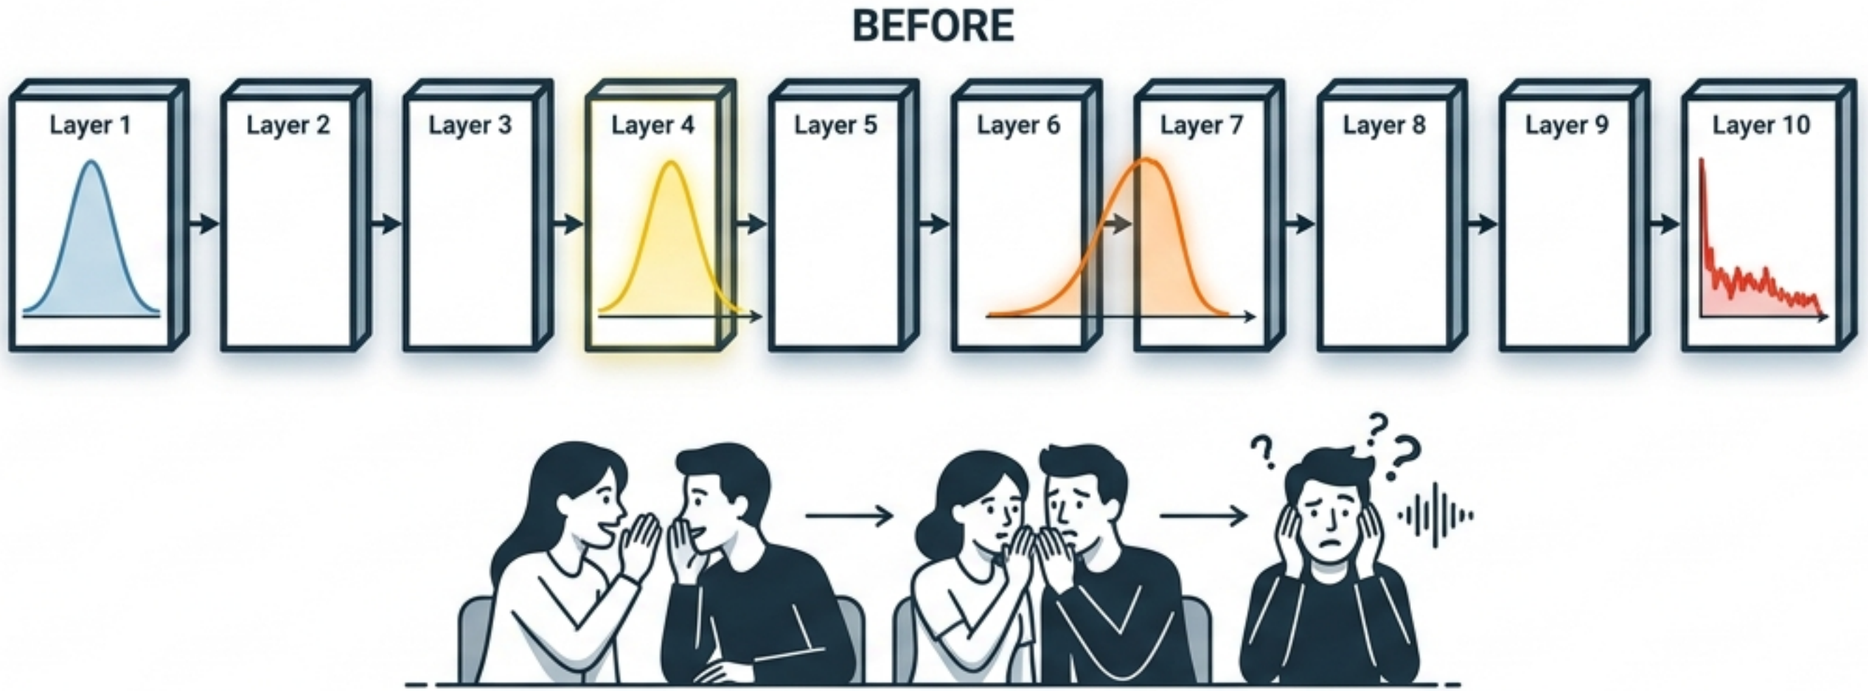
Chuẩn Hóa Lô (Batch Normalization)

Trái tim của Mạng Nơ-ron Hiện đại: Từ Lý thuyết Toán học đến Thực chiến trong Keras.

Dựa trên Chương 9: ConvNet Architecture Patterns.

Gemini Notebook

Vấn đề cốt lõi: Sự xô lệch phân phối nội bộ (Internal Covariate Shift)

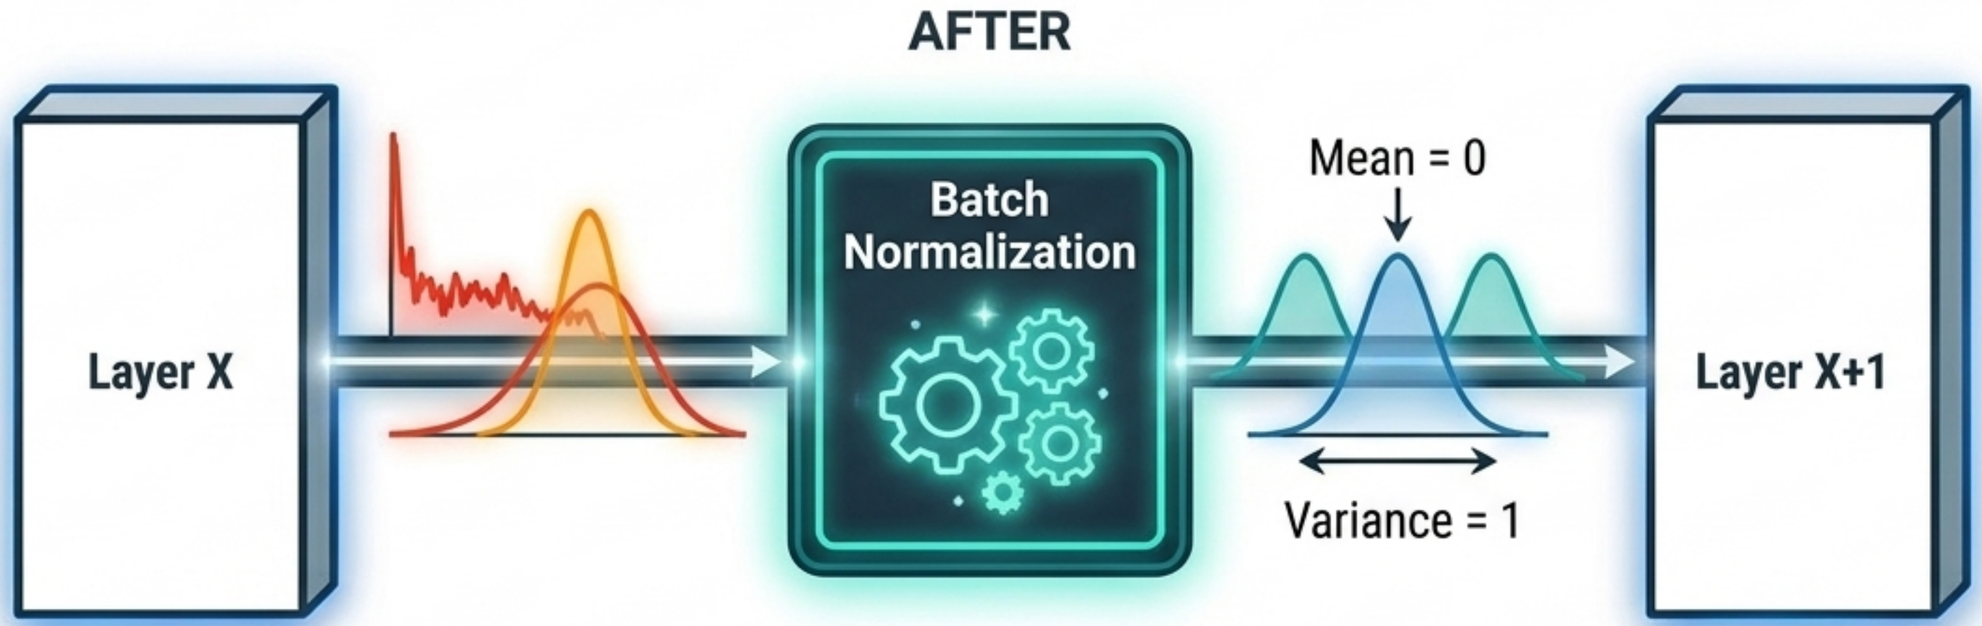


- Khi dữ liệu đi sâu vào hàng chục tầng ẩn, các giá trị kích hoạt liên tục bị biến đổi sau mỗi phép nhân ma trận.
- Các tầng phía sau luôn phải căng sức chạy theo sự thay đổi phân phối liên tục này.
- Kết quả: Quá trình học (Gradient Descent) bị chậm lại, và mạng nơ-ron dễ rơi vào trạng thái tắt tiếng (Vanishing Gradients).

Gemini Notebook

Giải pháp: Trạm điều hòa trung gian Batch Normalization

Được giới thiệu bởi **Sergey Ioffe & Christian Szegedy** (2015).



Lớp BatchNormalization hoạt động như một trạm kiểm soát, tự động tái chuẩn hóa dữ liệu ngay lập tức giữa các tầng, giúp dòng dữ liệu luôn ổn định khi di chuyển xuyên qua mạng.

Gemini Notebook

Phẫu thuật Hộp đen: 4 Bước Toán học của Batch Normalization

Lô dữ liệu **(Mini-Batch)** kích thước m

Bước 1: Tính Trung Bình (μ_B)



Tính trung bình của lô hiện tại.

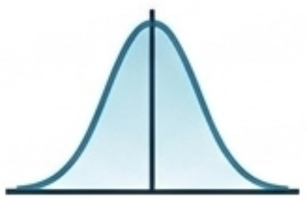
Bước 2: Tính Phương Sai (σ_B^2)



Tính độ phân tán của lô.

Bước 3: Chuẩn Hóa ($\hat{x}_i$)

$$\hat{x}_i = \frac{x_i - \mu_B}{\sqrt{\sigma_B^2 + \epsilon}}$$



Trừ đi trung bình, chia cho độ lệch chuẩn. Đưa về Phân phối chuẩn.

Bước 4: Scale và Shift

$$y_i = \gamma * \hat{x}_i + \beta$$



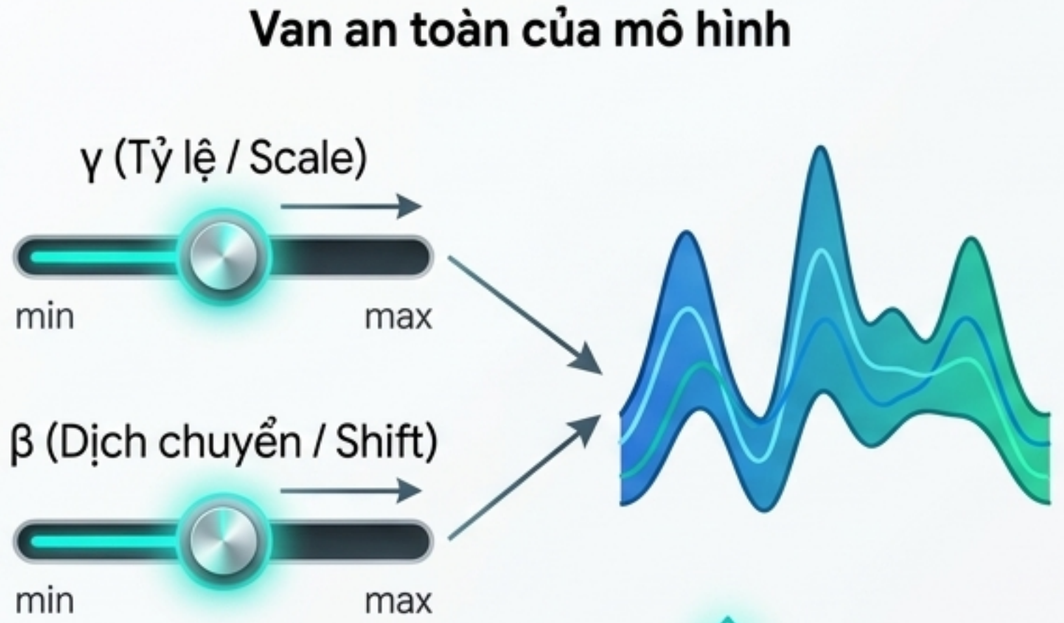
Phục hồi thông tin bằng 2 tham số học được: Scale & Shift.

Gemini Notebook

Ma thuật của γ và β: Van an toàn của mô hình



Nguy cơ: Nếu ép buộc chuẩn hóa 100%, mạng có thể vô tình xóa bỏ các đặc trưng hình học hữu ích.



γ và β không phải hằng số, chúng là tham số có thể học (learnable parameters) qua Gradient Descent. Nếu việc chuẩn hóa làm hỏng dữ liệu, mạng nơ-ron có thể tự dùng γ và β β đểkhôi phục lại nguyên trạng, cho phép mạng tự quyết định mức độ chuẩn hóa tối ưu!

Gemini Notebook

Chế độ Hoạt động: Huấn luyện (Training) vs. Dự đoán (Inference)

Trạng thái Huấn luyện (Training)	Trạng thái Dự đoán (Inference)
 **Mini-Batch** unnormalized data	 **Batch Size = 1** normalized data
Cơ chế: Tính toán trung bình (μ) và phương sai (σ^2) trực tiếp trên từng lô dữ liệu hiện tại.	**Cơ chế:** Không thể tính toán trên 1 mẫu. Sử dụng các hằng số trung bình động (EMA) đã tích lũy trong quá trình Training để chuẩn hóa.
Hành động ngầm: Âm thầm ghi nhớ trung bình động (Exponential Moving Average - EMA) của tất cả các lô đã đi qua.	**Kết quả:** Đảm bảo tính nhất quán và tốc độ tối đa khi dự đoán thực tế trên môi trường Production.

Gemini Notebook

Kỹ sư Keras Thực chiến: 3 Quy tắc Vàng

Biến lý thuyết thành mã nguồn tối ưu dựa trên **tiêu chuẩn kiến trúc** ConvNet hiện đại (Chương 9).

1 Vị trí Đặt Lớp (Placement)

2 Loại bỏ Bias (Bias Removal)

3 Đóng băng Trọng số (Fine-Tuning)

Gemini Notebook

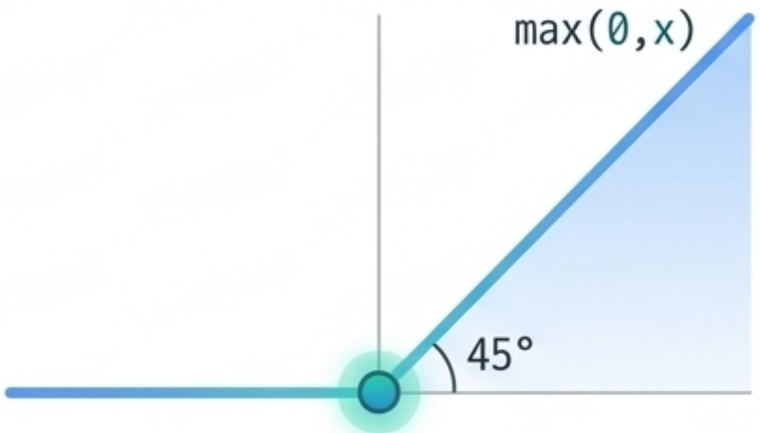
Quy tắc 1: Vị trí - Luôn đặt BN TRƯỚC hàm kích hoạt

Cách Cũ

```
x = layers.Conv2D(32, 3, activation="relu")(x)
x = layers.BatchNormalization()(x)
```

Chuẩn Chương 9

```
x = layers.Conv2D(32, 3, use_bias=False)(x)
x = layers.BatchNormalization()(x)
x = layers.Activation("relu")(x)
```



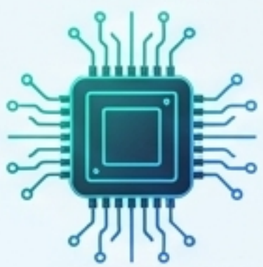
Tại sao? Lớp BN căn giữa dữ liệu về 0. Hàm ReLU sử dụng đúng số 0 làm **điểm tựa** (pivot) để quyết định giữ hay bỏ giá trị. Thực hiện chuẩn hóa trước giúp tối đa hóa **hiệu suất của ReLU**.

Gemini Notebook

Quy tắc 2: Tắt Bias - Tiết kiệm RAM & Tham số

$$y = \text{conv}(x, \text{kernel}) \cancel{+ \text{bias}}$$

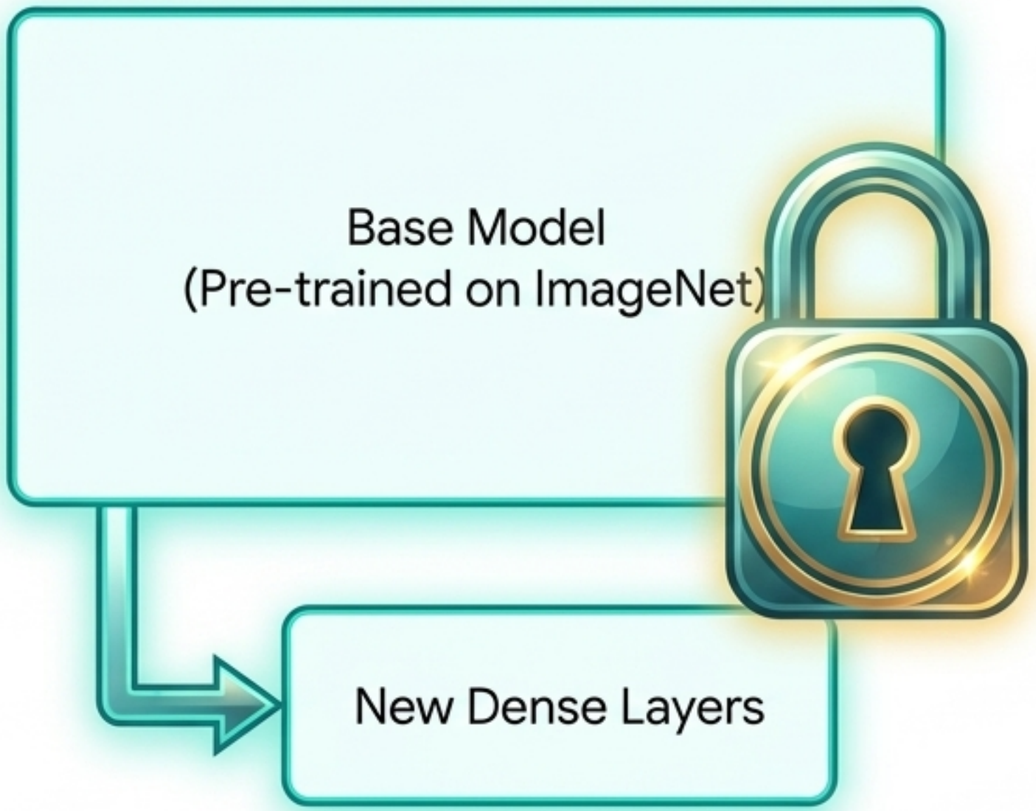
```
x = layers.Conv2D(32, 3, use_bias=False)(x)
```



Tại sao tắt? Lớp BatchNormalization ngay phía sau sẽ **lập tức trừ đi giá trị trung bình của toàn bộ lớp trước đó**. Nó cũng được trang bị **tham số dịch chuyển riêng (β)**. Do đó, vector bias của lớp Conv2D bị triệt tiêu hoàn toàn, trở nên dư thừa. Tắt nó đi giúp làm nhẹ mô hình, bớt lãng phí tài nguyên.

Gemini Notebook

Quy tắc 3: Đóng băng lớp BN khi Fine-Tuning




```
base_model.trainable = False
```

Nguy cơ nếu quên: Nếu không đóng băng (trainable=True), lớp BN sẽ tiếp tục cập nhật trung bình động (EMA) dựa trên dữ liệu mới của bạn. Sự xáo trộn ngầm này có thể phá hủy **hoàn toàn các trọng số Conv2D** vô cùng tinh tế đã được mô hình huấn luyện vất vả từ trước.

Gemini Notebook

Tổng hợp Thực chiến: Khối Residual trong Mini-Xception

1 Tự động chuẩn hóa dữ liệu dòng chảy.

Quy tắc 1: Đặt trước Activation và lớp Conv tiếp theo. 2

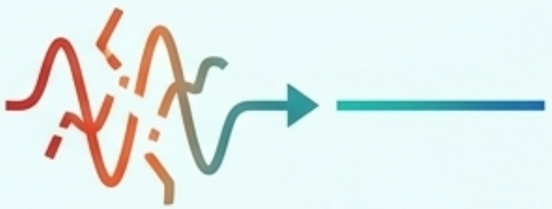
```
x = layers.BatchNormalization()(x)
x = layers.Activation("relu")(x)
x = layers.SeparableConv2D(size, 3, padding="same", use_bias=False)(x)
```

Quy tắc 2: Tắt bias để loại bỏ tham số thừa. 3

Tác dụng tổng hợp: Mạng thiết kế sâu hơn, tránh hoàn toàn rủi ro Vanishing Gradients, hội tụ nhanh và đạt độ chính xác tối ưu trong sản xuất.

Gemini Notebook

Bức tranh Toàn cảnh: Chuẩn Hóa Lô



Vấn đề & Giải pháp (The Why)

Chống xô lệch phân phối nội bộ (Internal Covariate Shift).

Hoạt động như một trạm điều hòa dữ liệu trung gian.



Trái tim Toán học (The Mechanics)

Chuẩn hóa lô hiện tại, sau đó dùng tham số γ và β để nội suy phục hồi đặc trưng.

Khác biệt cơ chế cốt lõi giữa Training và Inference (sử dụng EMA).



Kỹ thuật Lập trình (The Rules)

1. Đặt trước hàm `Activation`.
2. Loại bỏ tham số thừa (`use_bias=False`).
3. Bắt buộc đóng băng lớp khi áp dụng Transfer Learning.

Việc kết hợp Toán học sâu sắc và Kỹ thuật phần mềm tối ưu chính là cốt lõi của Kiến trúc Deep Learning hiện đại.

Gemini Notebook