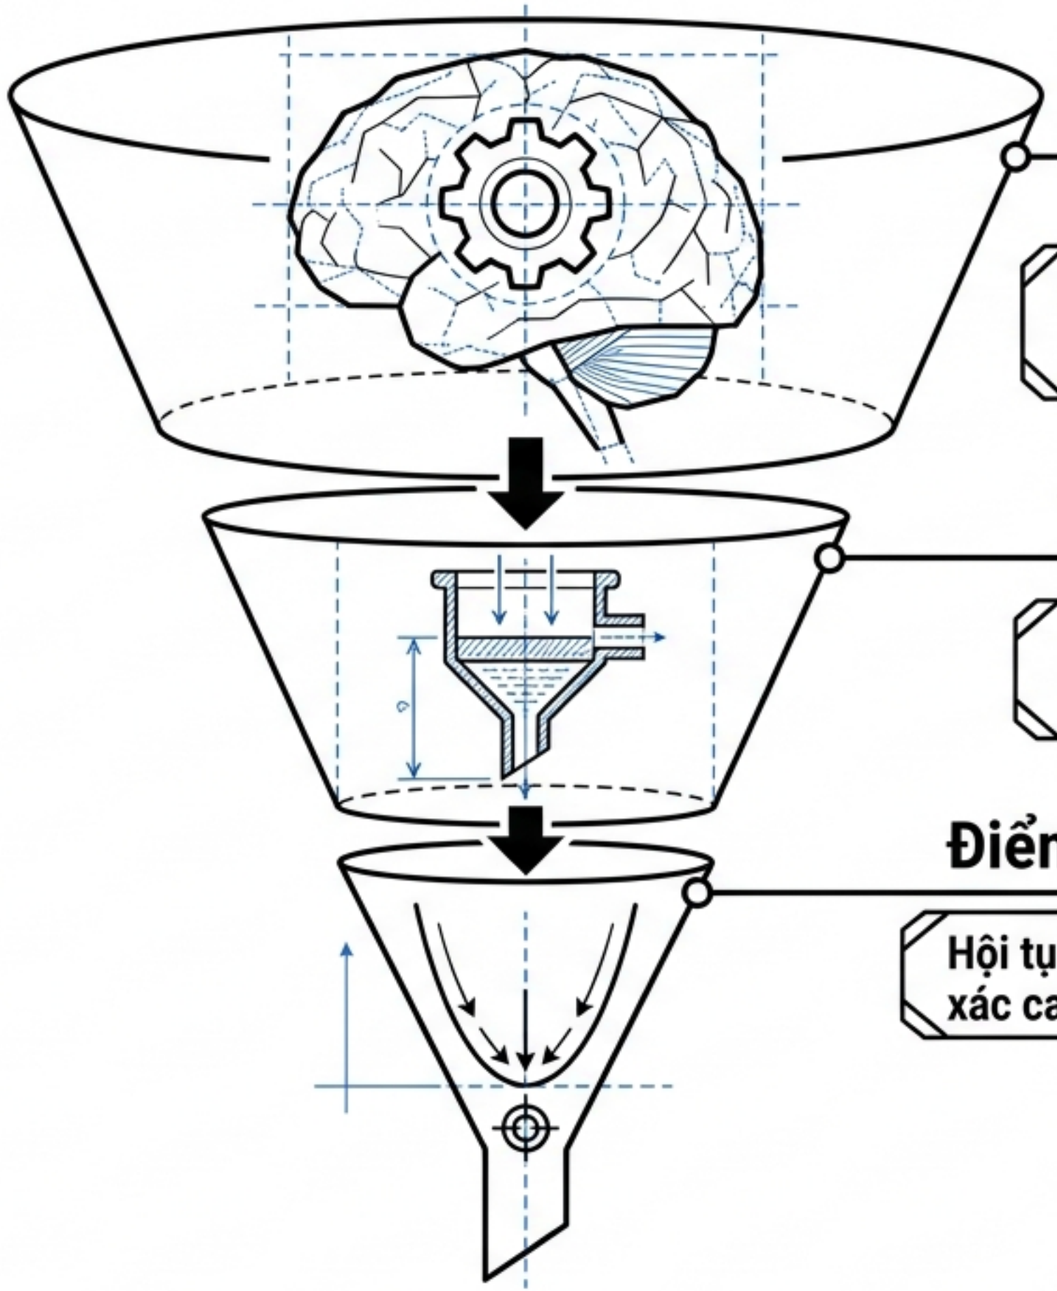


CHƯƠNG 9: CÁC MẪU KIẾN TRÚC MẠNG TÍCH CHẬP (CNN)

Bí quyết xây dựng mô hình Deep Learning tối ưu
từ nguyên lý cơ bản đến thực chiến.

Tài liệu bài giảng bậc Đại học | Cập nhật xu hướng thiết kế State-of-the-art.

Gemini Notebook



Không gian Giả thuyết (Hypothesis Space)

Mã hóa kiến thức nền tảng (prior knowledge). Ví dụ: Dùng ConvNet là giả ả định dữ liệu có tính bất biến tịnh tiến.

Thu hẹp Không gian Tìm kiếm

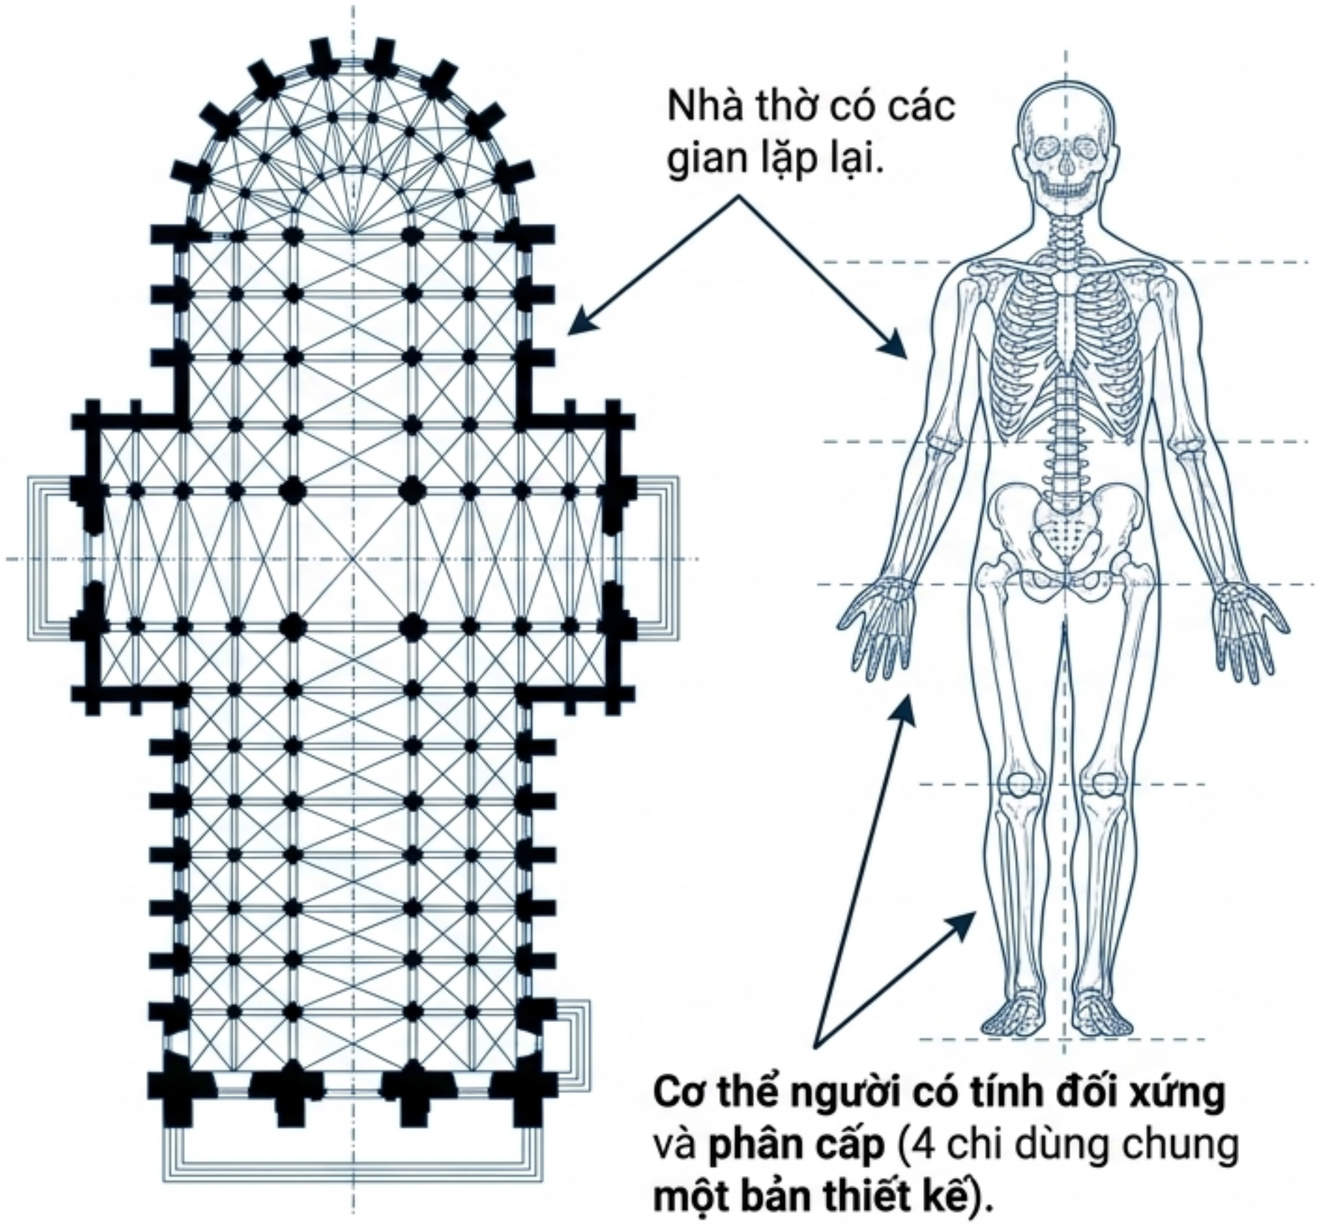
Loại bỏ nhiễu loạn, giúp thuật toán định hướng quỹ đạo hội tụ rõ ràng.

Điểm Tối ưu (Convergence)

Hội tụ nhanh hơn, cần ít dữ liệu hơn, độ chính xác cao hơn.

> “Kiến trúc mô hình cũng giống như việc thiết kế tính năng (feature engineering) – nó làm cho bài toán trở nên đơn giản hơn đối với Gradient Descent.”

Gemini Notebook



Cơ thể người có tính đối xứng và **phân cấp** (4 chi dùng chung **một bản thiết kế**).

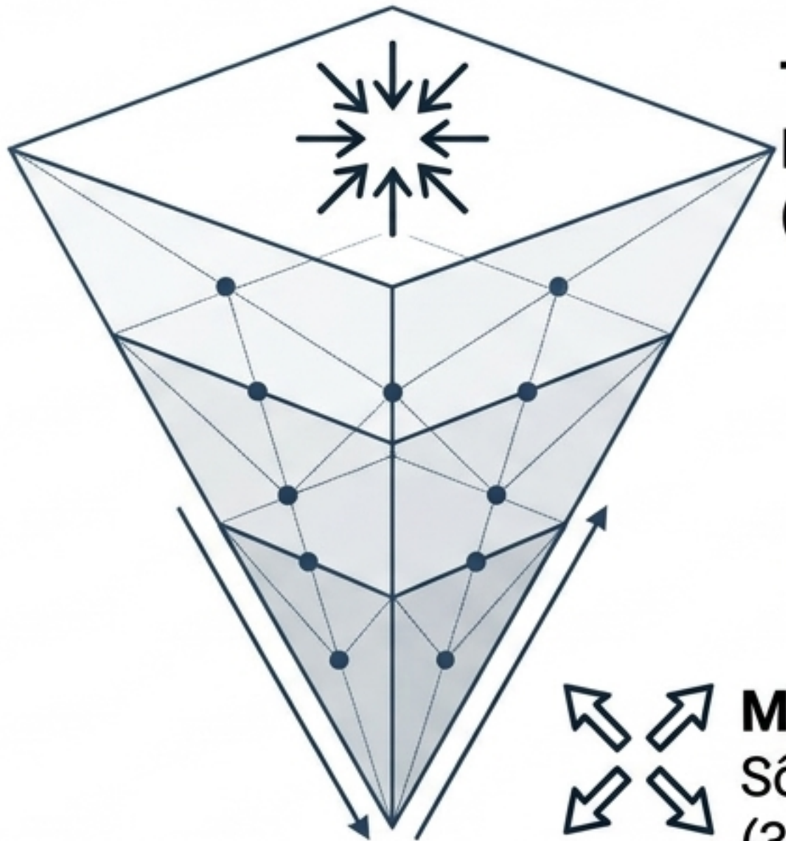
Công thức chung kiểm soát hệ thống phức tạp

M — **Modularity (Tính Mô-đun):** Chia hệ thống thành các khối (blocks) độc lập.

H — **Hierarchy (Tính Phân cấp):** Xếp chồng các khối thành cấu trúc thứ bậc.

R — **Reuse (Tái sử dụng):** Lặp lại cùng một cấu hình mô-đun ở nhiều nơi.

Gemini Notebook

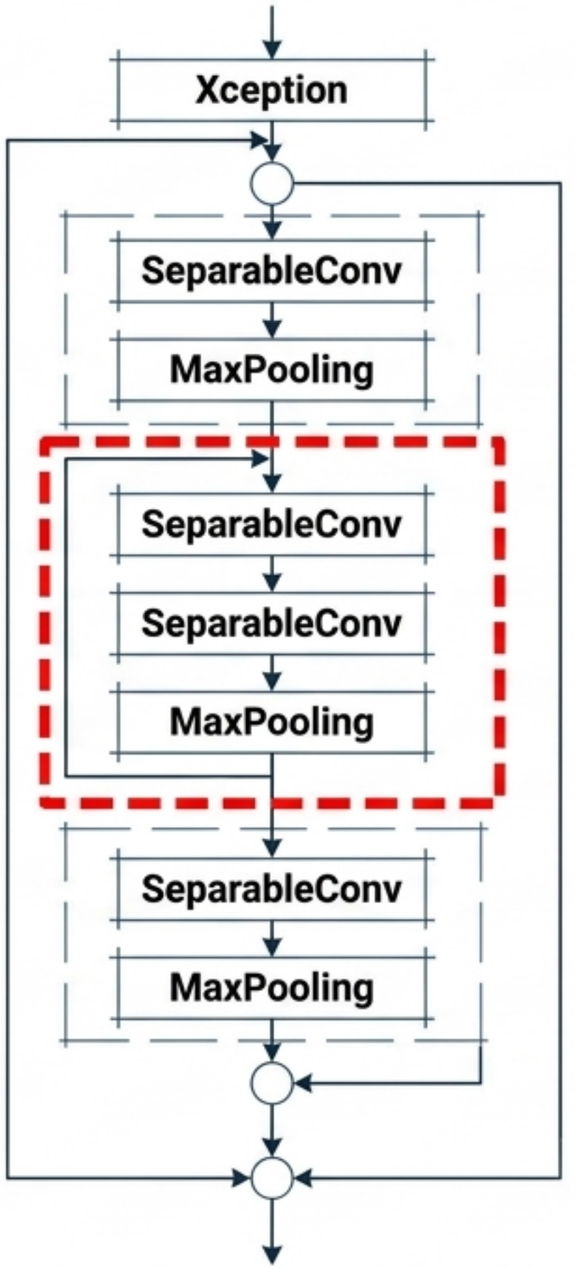


Thu hẹp không gian:
Kích thước ảnh giảm dần (299x299 → 19x19).

Mở rộng chiều sâu:
Số lượng bộ lọc tăng dần (32 → 728).

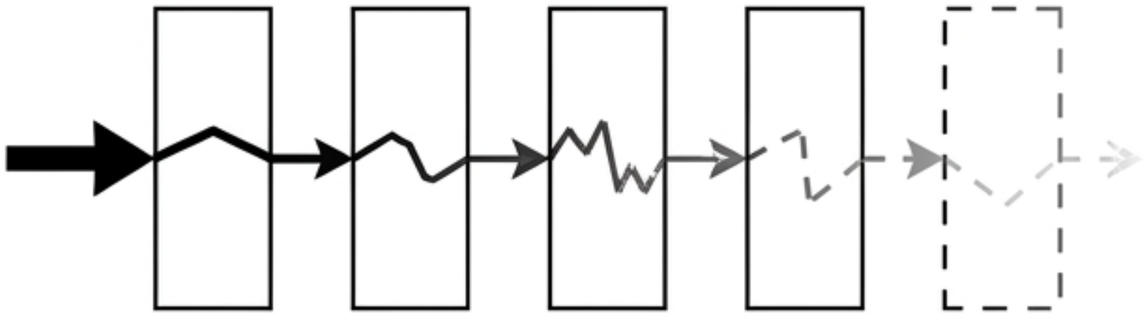
Nguyên tắc Vàng

Sâu và Hẹp (Deep & Narrow) luôn cho **hiệu quả cao hơn Nông và Rộng.**



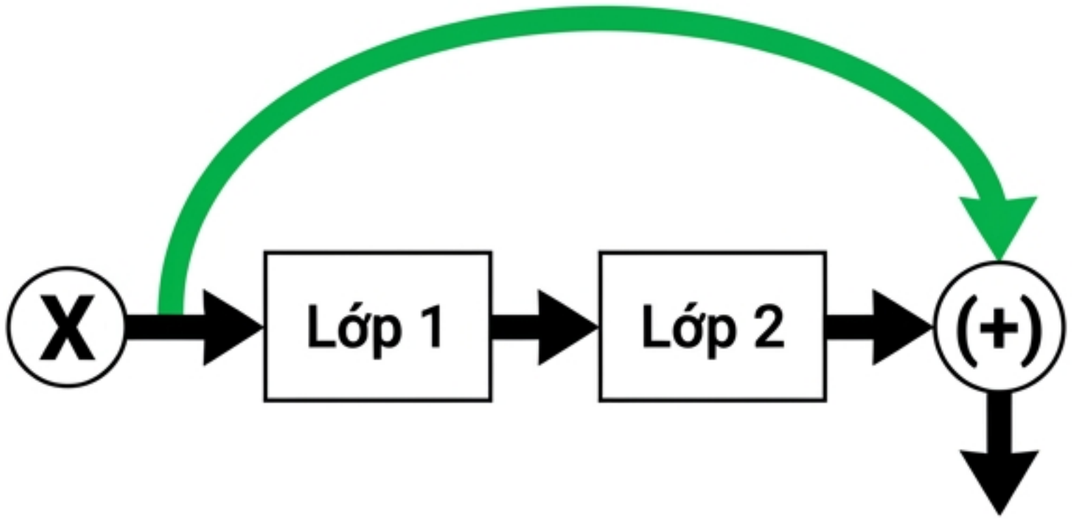
Gemini Notebook

Vấn đề: Suy biến đạo hàm / Vanishing Gradients



Mô hình ngừng học khi mạng quá sâu do tín hiệu đạo hàm bị triệt tiêu qua các lớp phi tuyến.

Giải pháp: Kết nối Thặng dư / ResNet 2015



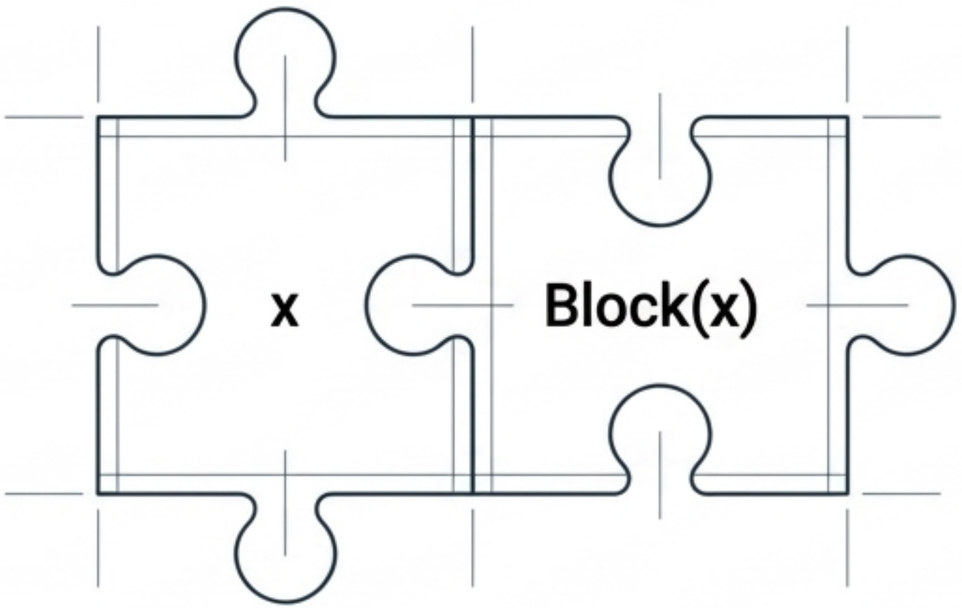
Output = Block(x) + x

Tạo một **"đường cao tốc"** mang **nguyên vẹn dữ liệu đầu vào cộng thẳng vào đầu ra, giữ tín hiệu không bị nhiễu.**

Gemini Notebook

Điều kiện bắt buộc: x và **Block(x)** phải có cùng kích thước (shape).

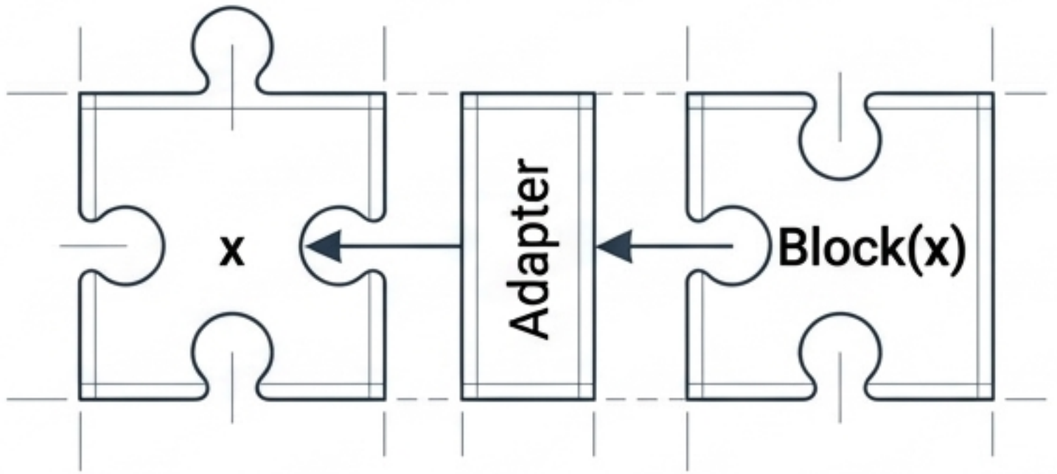
Trường hợp 1: Khớp Kích thước



Cộng trực tiếp:

```
x = layers.add([x, residual])
```

Trường hợp 2: Lệch Kích thước

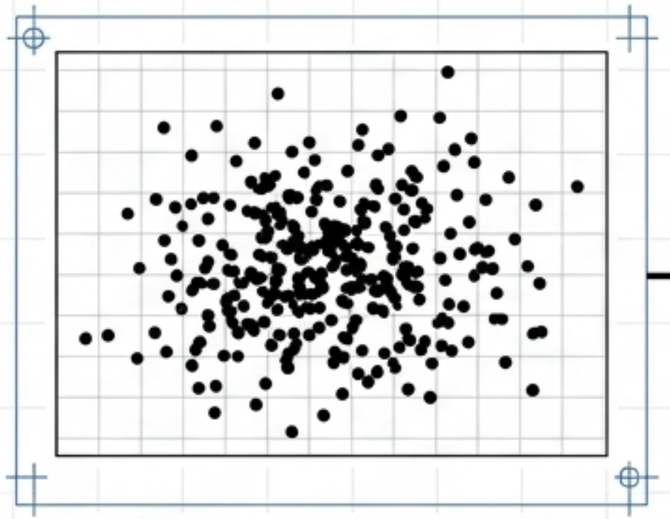


Giải pháp: Dùng Conv2D(1x1) để chiếu tuyến tính về đúng kích thước. Thêm strides=2 nếu nhánh chính có MaxPooling.

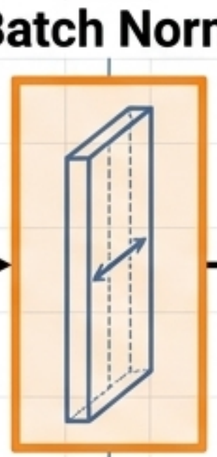
```
residual = layers.Conv2D(filters, 1, strides=2)(residual)
```

Gemini Notebook

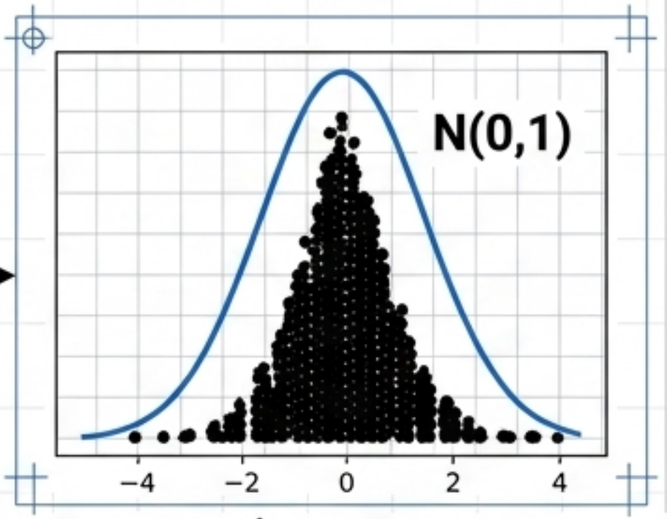
Giải pháp: **Chuẩn hoá theo lô (Batch Normalization - BN)**



Dữ liệu thô (chaotic)



Batch Norm



Dữ liệu chuẩn hoá (normalized)

Kéo **giá trị trung bình (Mean) về 0 và độ lệch chuẩn (Variance) về 1** cho từng lô (batch).
Giúp lan truyền gradient mượt mà cho mạng cực sâu.

Conv2D (use_bias=False) → **Batch Normalization** → **Activation (ReLU)**

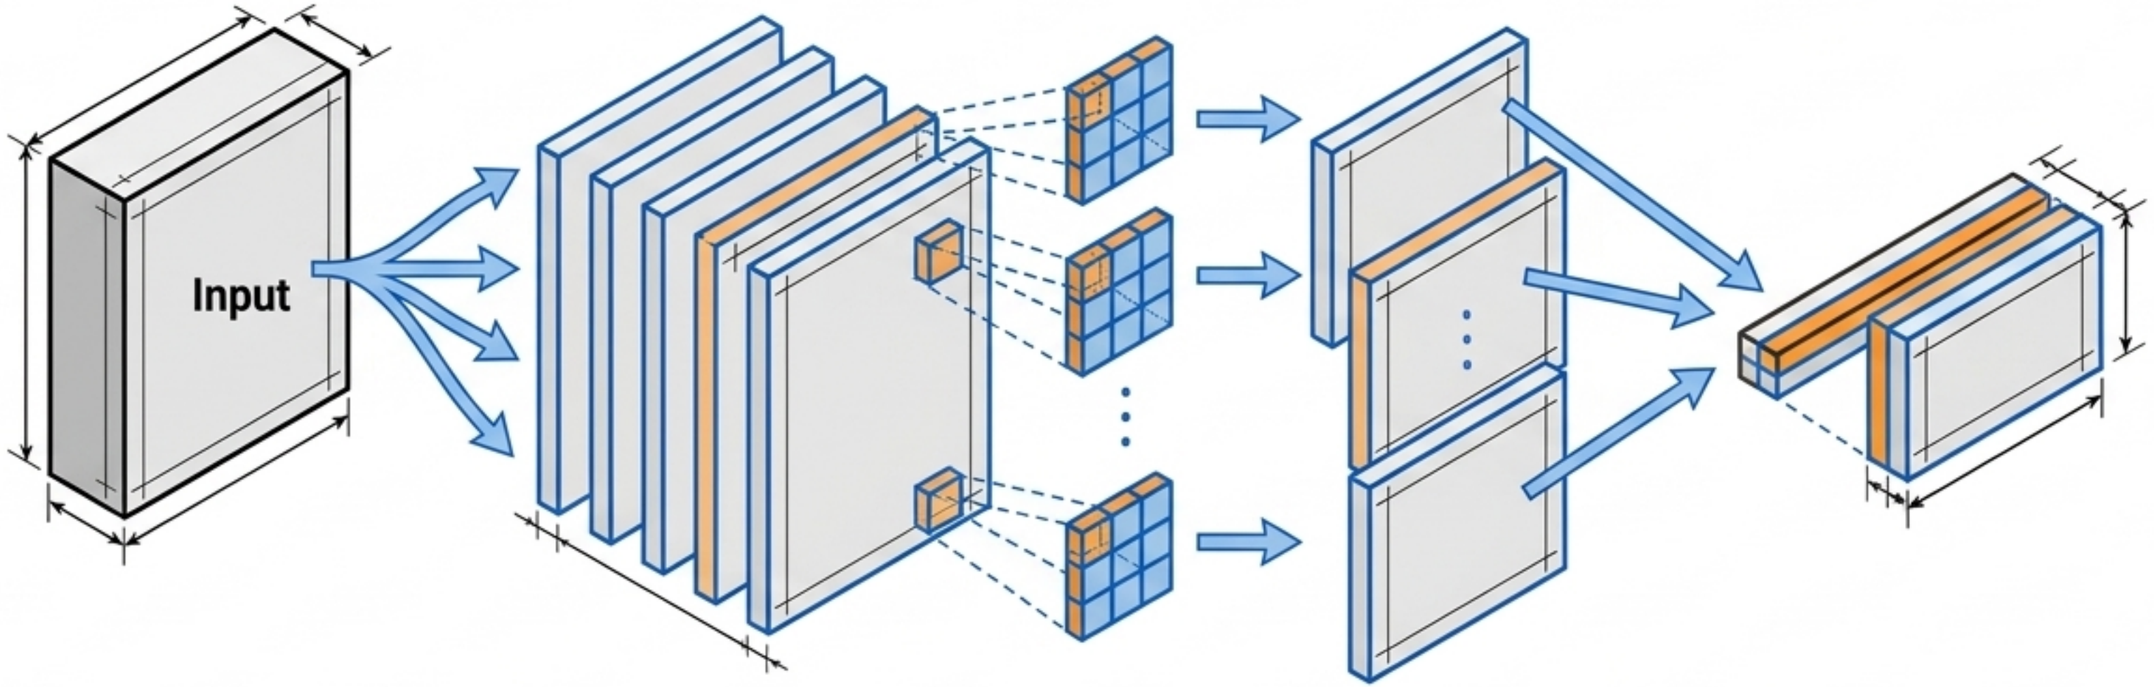
CẢNH BÁO LẬP TRÌNH: Đặt **BN** sau **Conv2D** và **trước ReLU**. Bắt buộc tắt bias ở lớp **Conv2D (use_bias=False)** vì BN đã tự động căn trung bình về 0.

Gemini Notebook

Tích chập Tách rời (SeparableConv2D): Nhẹ hơn, Nhanh hơn, Chính xác hơn.

Bước 1: Học Không gian (Depthwise) →
Áp dụng bộ lọc 3x3 cho từng kênh riêng biệt.

Bước 2: Trộn Kênh (Pointwise) →
Dùng Conv 1x1 để kết hợp thông tin.



Giả thuyết nền tảng: "Vị trí không gian có tính tương quan cao, nhưng các kênh thì độc lập với nhau". Kỹ thuật này giúp loại bỏ sự dư thừa toán học của Conv2D thông thường.

Gemini Notebook

Bài toán: Cửa sổ 3x3, 64 kênh đầu vào, 64 kênh đầu ra.

Conv2D Tiêu chuẩn	SeparableConv2D
3 x 3 x 64 x 64	(3 x 3 x 64) + (64 x 64)
36,864 →	**4,672**

Giảm ~87% tham số! Mô hình nhỏ hơn → Giảm Overfitting → Hội tụ nhanh hơn. Đặc biệt quan trọng khi dữ liệu giới hạn.

Gemini Notebook

Tổng hợp Checklist Thiết kế CNN Hiện đại

✅ Tổ chức Mô-đun (Modularity)

Gom các lớp thành các khối lặp lại.

✅ Tháp Đặc trưng (Hierarchy)

Không gian giảm dần, số lượng Filter tăng dần.

✅ Deep & Narrow

Ưu tiên mạng thiết kế sâu và hẹp thay vì nông và rộng.

✅ Đường tắt (Residuals)

Bọc các khối bằng **Residual connection** để bảo toàn gradient.

✅ Chuẩn hóa (Batch Norm)

Đặt BN sau Conv (tắt Bias) và trước hàm Activation.

✅ Tối ưu (SeparableConv)

Thay thế Conv2D bằng SeparableConv2D (trừ lớp đầu tiên xử lý RGB).

Gemini Notebook

Dùng **Conv2D** thường vì 3 kênh màu RGB tương quan cực mạnh, **không thể tách rời ngay lập tức.**

```
inputs = keras.Input(shape=(224, 224, 3))

x = layers.Conv2D(32, 3, strides=2, padding="same")(inputs)
x = layers.BatchNormalization()(x)
x = layers.Activation("relu")(x)

for size in [64, 128, 256, 512]:
    residual = x
    x = layers.BatchNormalization()(x)
    x = layers.Activation("relu")(x)
    x = layers.SeparableConv2D(size, 3, padding="same", use_bias=False)(x)

    x = layers.BatchNormalization()(x)
    x = layers.Activation("relu")(x)
    x = layers.SeparableConv2D(size, 3, padding="same", use_bias=False)(x)

    x = layers.MaxPooling2D(3, strides=2, padding="same")(x)

    residual = layers.Conv2D(size, 1, strides=2, padding="same")(residual)
    x = layers.add([x, residual])

x = layers.GlobalAveragePooling2D()(x)
outputs = layers.Dense(10, activation="softmax")(x)
model = keras.Model(inputs, outputs)
```

Vòng lặp thể hiện nguyên lý lặp lại và tháp đặc trưng (size tăng dần: 32, 64, 128, 256, 512).

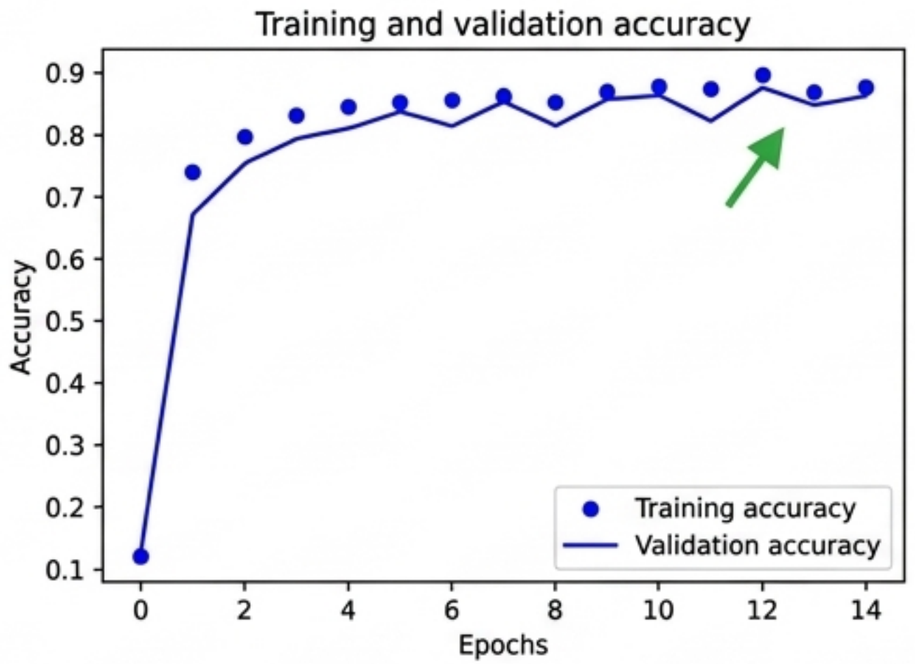
Áp dụng đầy đủ **Chuẩn hóa** (Batch Norm), Hàm **kích hoạt** (ReLU), và **SeparableConv** (với use_bias=False).

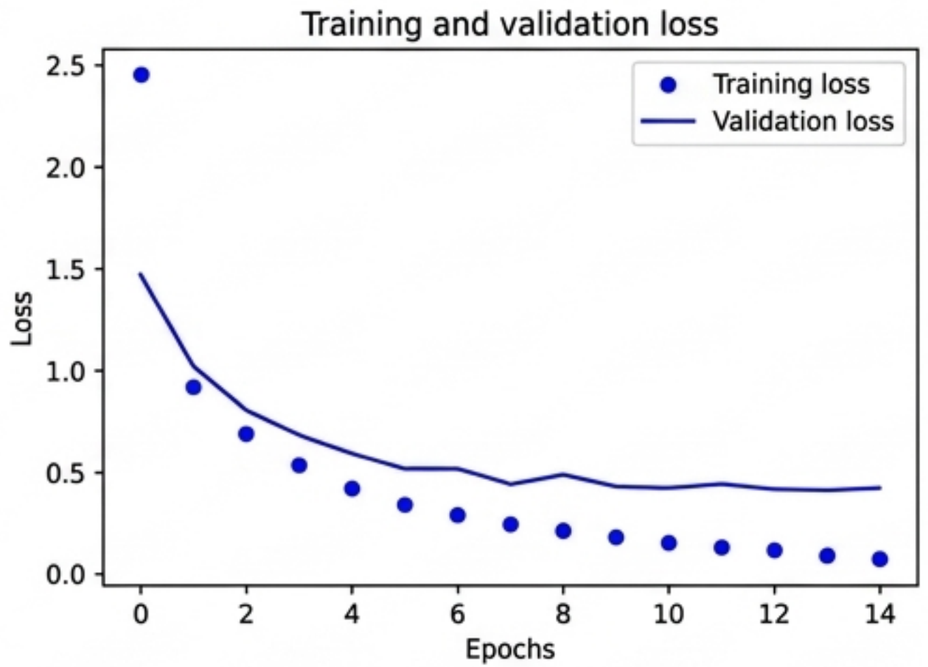
Dùng Conv2D(1x1, strides=2) để chiếu nhánh thặng dư (residual) khớp hoàn hảo với phép MaxPooling.

Gemini Notebook

The Architect's Blueprint

CNN Cổ điển	Mini-Xception
Tổng tham số: **~1.57 triệu** Độ chính xác: **83.9%**	Tổng tham số: **~721 ngàn** (Chỉ bằng 1/2!) Độ chính xác: **90.8%**



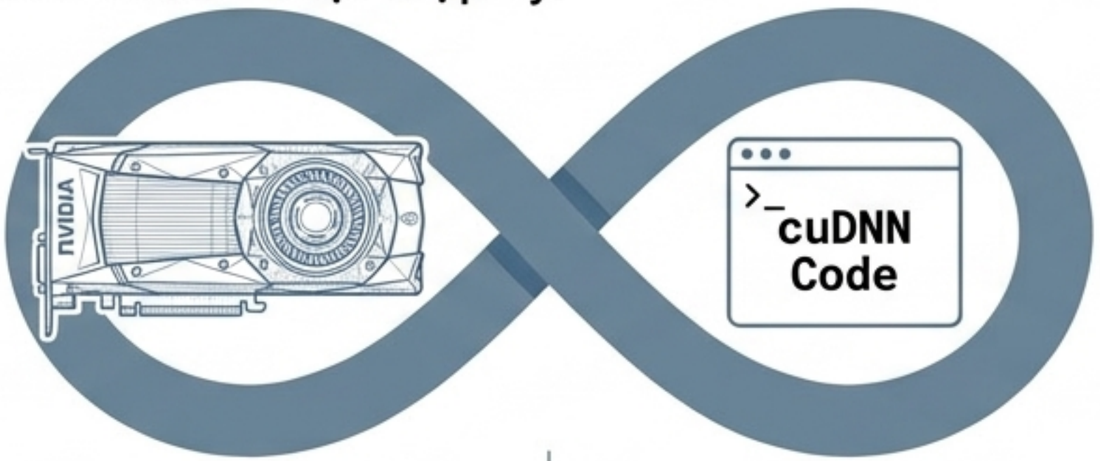


Cấu trúc tốt bù đắp cho kích thước mô hình. Một thiết kế đúng chuẩn tạo ra khác biệt ngay lập tức.

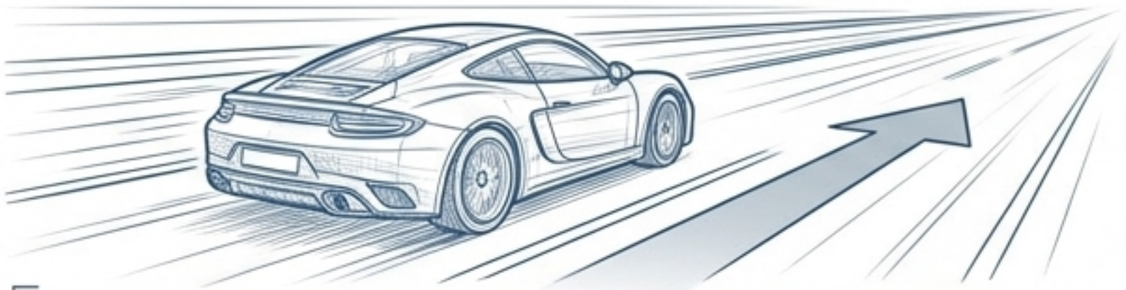
Gemini Notebook

Nghịch lý tốc độ: Phần cứng vs Thuật toán

Sự **Đồng tiến hóa (Co-evolution)**: Phần cứng và phần mềm đã được vi mô tối ưu hóa **(micro-optimized)** cho **Conv2D** suốt một thập kỷ.



Conv2D + cuDNN



SeparableConv
(Thiếu tối ưu phần cứng)



Thực tế: Dù SeparableConv có ít phép tính hơn, **tốc độ chạy trên GPU hiện tại** chỉ ngang bằng **Conv2D**. Tuy nhiên, **nó vẫn hoàn toàn ưu việt** nhờ **khả năng giảm đáng kể** kích thước mô hình và chống Overfitting.

Gemini Notebook

Kỷ nguyên mới: CNNs vs Vision Transformers (ViTs)

Convolutional Neural Networks (CNNs)	Vision Transformers (ViTs)
	
Mạnh về quy tắc cục bộ (Local spatial prior).	Chia ảnh thành các mảnh (patches), bắt được liên kết không gian xa (Long-range dependencies).
Hoạt động cực kỳ hiệu quả với tập dữ liệu nhỏ và vừa.	Lên ngôi khi có lượng dữ liệu khổng lồ (Large-scale / Generative AI).
Lựa chọn tối ưu, nhanh chóng cho các bài toán thông thường.	Quá cồng kềnh, thiếu hiệu quả nếu áp dụng cho dữ liệu nhỏ.

Gemini Notebook

Lời Kết & Bài học Rút ra



Thực nghiệm (Empiricism)

Nhiều kỹ thuật (như Batch Norm) chứng minh hiệu quả qua thực tiễn hơn là toán học tuyệt đối. Luôn dùng Nghiên cứu Cắt bỏ (Ablation Studies) để hiểu nhân quả.



Sự Thanh lịch của MHR

Mọi hệ thống phức tạp đều có thể được làm chủ và đơn giản hóa thông qua Tính Mô-đun (Modularity), Phân cấp (Hierarchy) và Tái sử dụng (Reuse).



Tiêu chuẩn Mới

Tích hợp Kết nối thặng dư (Residuals), Chuẩn hóa (Batch Norm) và Tích chập tách rời (SeparableConv) vào mạng CNN của bạn ngay hôm nay để đạt hiệu suất State-of-the-art.

Gemini Notebook