Học Sâu (Deep Learning)

Chương 10: Diễn dịch và Trực quan hóa Mạng Tích chập (Interpreting what ConvNets learn)

Đại học Đông Á

August 14, 2026

Nội dung chương

1. 1. Vấn đề "Hộp Đen" trong Deep Learning
2. 2. Trực quan hóa Biểu diễn Trung gian
3. 3. Trực quan hóa Bộ lọc bằng Gradient Ascent
4. 4. Bản đồ Kích hoạt Lớp (Grad-CAM)
5. Tổng kết

Deep Learning có phải là Hộp Đen (Black Box)?

- Định kiến phổ biến cho rằng Mạng nơ-ron là những chiếc "Hộp đen", không thể giải thích được lý do nó đưa ra quyết định (Black Box Problem).
- Khả năng diễn dịch (**Interpretability**) là yêu cầu bắt buộc trong các lĩnh vực rủi ro cao:
  - **Y tế:** "Tại sao AI lại chẩn đoán bệnh nhân này bị ung thư?"
  - **Xe tự lái:** "Tại sao AI lại không nhận ra chiếc xe tải phía trước?"
- Thực tế: Định kiến "Hộp đen" **KHÔNG** đúng với Mạng Tích chập (ConvNets).
- ConvNets học các biểu diễn hình ảnh không gian 2D, do đó chúng ta có thể **trực quan hóa** những gì nó đang "nhìn" thấy.

Các phương pháp Trực quan hóa ConvNet

Trong chương này, chúng ta sẽ khảo sát 3 phương pháp cốt lõi nhất để mở khóa hộp đen ConvNet:

1. **Trực quan hóa Bản đồ đặc trưng trung gian (Intermediate Activations):** Giúp ta hiểu mô hình đang "nhìn" thấy những chi tiết nào của ảnh.
2. **Trực quan hóa Bộ lọc (Filter Visualization):** Sử dụng Gradient Ascent để vẽ ra các mẫu họa tiết (Pattern) lý tưởng mà mỗi Bộ lọc khát khao tìm kiếm nhất.
3. **Bản đồ Kích hoạt Lớp (Grad-CAM):** Trả lời câu hỏi "Tại sao AI đưa ra quyết định phân loại này?" thông qua một Bản đồ nhiệt (Heatmap) chỉ thẳng vào vùng ảnh quan trọng.

Kỹ thuật 1: Trực quan hóa Bản đồ Đặc trưng (Feature Maps)

- **Mục tiêu:** Hiểu cách các lớp Tích chập liên tiếp (Successive Layers) biến đổi và bóc tách một hình ảnh đầu vào.
- **Khái niệm Kích hoạt (Activations):** Đầu ra của một lớp Tích chập (bao gồm cả chiều không gian H, W và số kênh C) được gọi là Activation.
- Mỗi kênh (Channel) trong bản đồ đặc trưng hoạt động như một bộ dò mẫu (Pattern Detector) tương đối độc lập. Do đó ta sẽ xuất hình ảnh của từng Kênh ra màn hình để phân tích.

Ví dụ Đầu vào

- Ta đưa một bức ảnh con mèo (hoàn toàn mới, không có trong tập huấn luyện) vào mạng CNN phân loại Chó-Mèo đã được train ở Chương 8.
- Hãy xem cách các lớp Tích chập phản ứng (Activate) với bức ảnh này.



Hình 10.1: Hình ảnh con mèo thử nghiệm

Tiền xử lý ảnh gốc

Chúng ta dùng `keras.utils` để load ảnh gốc và chuyển nó thành mảng numpy Tensor sẵn sàng đưa vào mô hình.

```
import keras
import numpy as np
import matplotlib.pyplot as plt

img_path = "cat.jpg"
def get_img_array(img_path, target_size):
    # Opens the image file and resizes it
    img = keras.utils.load_img(img_path, target_size=target_size)
    # Turns the image into a float32 NumPy array
    array = keras.utils.img_to_array(img)
    # We add a dimension to transform our array into a "batch"
    array = np.expand_dims(array, axis=0)
    return array

img_tensor = get_img_array(img_path, target_size=(180, 180))
```

Xây dựng Mô hình Đa Đầu ra (Multi-output Model)

Để trích xuất các bản đồ đặc trưng ở giữa mạng (Intermediate), ta phải định nghĩa một Model đặc biệt nhận 1 đầu vào nhưng xuất ra **nhiều đầu ra** tương ứng với mọi lớp Conv2D.

```
from keras import layers

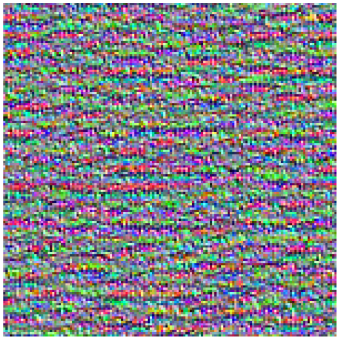
layer_outputs = []
layer_names = []
# Extracts the outputs of all Conv2D and MaxPooling2D layers
for layer in model.layers:
    if isinstance(layer, (layers.Conv2D, layers.MaxPooling2D)):
        layer_outputs.append(layer.output)
        layer_names.append(layer.name)

# Creates a model that will return these outputs
activation_model = keras.Model(inputs=model.input, outputs=layer_outputs)

# Returns a list of nine NumPy arrays
activations = activation_model.predict(img_tensor)
```

Kích hoạt của các Bộ lọc Đơn lẻ (Single Filter)

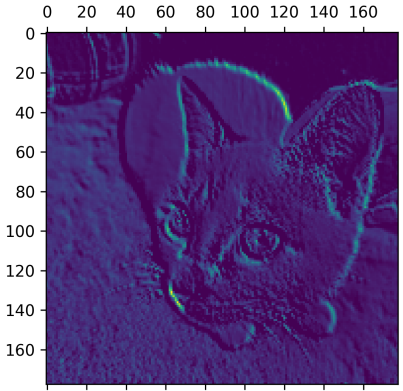
- Quan sát một kênh ở **Lớp đầu tiên** của mô hình. Kích thước Tensor: `(1, 178, 178, 32)`.
- Lớp này giữ lại gần như toàn bộ thông tin không gian chi tiết của con mèo.
- Kênh này đang hoạt động như một công cụ **Dò tìm Cạnh (Edge Detector)**, cực kỳ nhạy cảm với các đường viền nghiêng.



Hình 10.2: Đặc trưng Kênh số 4 (Lớp Conv đầu tiên)

Kích hoạt Kênh đặc biệt (Mắt mèo)

- Một kênh khác ở cùng lớp đầu tiên lại có nhiệm vụ hoàn toàn khác.
- Kênh số 5 này đặc biệt nhạy cảm với những **đốm sáng hình tròn** (như con ngươi của mắt mèo) và bỏ qua hầu hết các thông tin về lông hoặc cạnh tai.
- Quá trình chuyên môn hóa của các nơ-ron đã bắt đầu ngay từ lớp nông nhất.



Hình 10.3: Đặc trưng Kênh số 5 (Bắt dính Mắt mèo)

Trực quan hóa Toàn bộ Các kênh của Mạng (Phần 1)

Viết một vòng lặp `for` lồng nhau để lấy từng kênh ra và vẽ thành một lưới (Grid) ma trận lớn.

```
images_per_row = 16
for layer_name, layer_activation in zip(layer_names, activations):
    n_features = layer_activation.shape[-1]
    size = layer_activation.shape[1]
    n_cols = n_features // images_per_row
    display_grid = np.zeros(
        ((size + 1) * n_cols - 1, images_per_row * (size + 1) - 1)
    )
    for col in range(n_cols):
        for row in range(images_per_row):
            channel_index = col * images_per_row + row
            channel_image = layer_activation[0, :, :, channel_index].copy()
```

Trực quan hóa Toàn bộ Các kênh của Mạng (Phần 2)

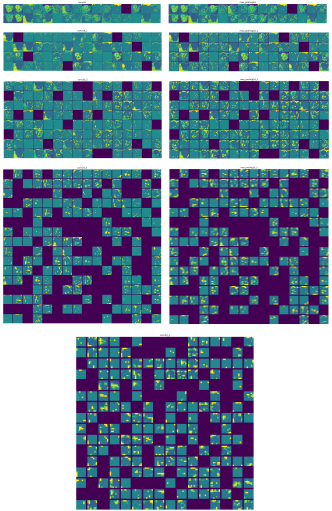
Ta cần Normalize giá trị của từng channel về phổ màu $0 - 255$ để màn hình máy tính có thể render được.

```
            # Normalizes channel values within the [0, 255] range.
            if channel_image.sum() != 0:
                channel_image -= channel_image.mean()
                channel_image /= channel_image.std()
                channel_image *= 64
                channel_image += 128
            channel_image = np.clip(channel_image, 0, 255).astype("uint8")

            # Places the channel matrix in the empty grid
            display_grid[
                col * (size + 1) : (col + 1) * size + col,
                row * (size + 1) : (row + 1) * size + row,
            ] = channel_image
```

Mạng Tích chập học được gì? (Lưới Kích hoạt)

- Khi tiến sâu hơn vào mạng, các bản đồ đặc trưng trở nên **thưa thớt (Sparse)** và **trừu tượng (Abstract)**.
- Chúng không còn chứa hình dáng vật lý của con mèo nữa, mà chuyển sang lưu giữ các Khái niệm (Ví dụ: "Có tai mèo trong vùng không gian này hay không?").
- Các ô trống đen xì nghĩa là bộ lọc đó hoàn toàn không tìm thấy mẫu mà nó cần.



Sự chưng cất thông tin (Information Distillation)

- Chúng ta vừa quan sát một hiện tượng phổ quát của Deep Learning: **Các tầng sâu sẽ học các đặc trưng trừu tượng hơn**.
- Mạng AI hoạt động như một **Ống chưng cất thông tin** (Information Distillation Pipeline).
- Các thông tin thừa thãi mang tính tiểu tiết (màu sắc lông, nền tường) sẽ bị lặp tức gạt bỏ. Những thông tin sống còn mang tính phân loại (có tai nhọn, có ria mép) sẽ được phóng đại và lưu giữ.
- Điều này giống hệt cách não bộ con người hoạt động: Khi nhìn 1 chiếc xe đạp, bạn chỉ nhớ "Đây là xe đạp" chứ không thể nhớ số nan hoa hay màu phanh xe.

Kỹ thuật 2: Gradient Ascent trên Không gian Ảnh

- **Mục tiêu:** Thay vì xem Bộ lọc phản ứng với ảnh thật như thế nào, ta hãy **tự tạo ra một bức ảnh ảo** (từ mảng nhiễu trắng ngẫu nhiên) sao cho Bộ lọc đó phản ứng cực đại.
- Bức ảnh ảo sinh ra chính là hiện thân cho "Mẫu lý tưởng" (Ideal Pattern) mà Bộ lọc đó đang khát khao tìm kiếm.
- Đây là thuật toán **Gradient Ascent (Leo đồi Gradient)**, đi ngược lại với Gradient Descent truyền thống.